

پرسش ۱. طراحی گام به گام VAE (۲۰ نمره)

در این تمرین قصد داریم به صورت گام به گام یک مدل VAE را توسعه دهیم. به دلیل وابستگی بین صورت سوال هر بخش به جواب بخش قبل، در صورت هرگونه ابهام یا سوال می‌توانید در تلگرام ابهامات خود را بر طرف نمایید (ایدی طراح: @Alireza_1197). در ادامه پیش‌فرض‌های مسئله آمده است:

فرضیات:

ما مدل خود را بر پایه‌ی یک معماری **encoder-decoder** با یک متغیر نهان پیوسته توسعه خواهیم داد. مؤلفه‌های کلیدی عبارتند از:

- **داده‌ها:** مجموعه‌ای از مشاهدات $D = \{X^{(i)}\}_{i=1}^N$ ، که در آن هر داده‌ی $X^{(i)} \in \mathbb{R}^n$ است.
- **فضای نهان (Latent Space):** یک متغیر نهان $Z \in \mathbb{R}^m$ که اطلاعات فشرده‌شده‌ای از ورودی را نمایش می‌دهد.
- **مدل مولد (Decoder):** توزیع خروجی را یک توزیع گاوسی به شرط توابعی از متغیر نهان تعریف می‌کند:

$$p_{\theta}(X | Z) = \mathcal{N}(X | \mu_{\theta}(Z), \Sigma_{\theta}(Z))$$

که در آن Decoder نگاشت Z به پارامترهای خروجی را انجام می‌دهد:

$$\mu_{\theta}(Z) = \text{NN}_{\alpha}(Z), \quad \Sigma_{\theta}(Z) = \text{diag}(\sigma(\text{NN}_{\beta}(Z)))$$

- **توزیع پیشین (Prior):** متغیر پنهان از یک توزیع گاوسی چندمتغیره نمونه‌گیری می‌شود:

$$p(Z) = \mathcal{N}(Z | \mu_z, \sigma_z^2 I)$$

- **پارامترهای مدل:** مجموعه پارامترهای قابل آموزش $\theta = \{\mu_z, \sigma_z^2, \alpha, \beta\}$ ، که α و β وزن‌های شبکه Decoder هستند.

گام ۱: برآورد درست‌نمایی (Likelihood Estimation)

در مدل‌های مولد، هدف بیشینه کردن درست‌نمایی داده‌های مشاهده‌شده در توزیع خروجی مدل است.

(الف) یک عبارت برای درست‌نمایی حاشیه‌ای $p_{\theta}(X)$ برای یک نمونه‌ی داده X استخراج کنید.

(ب) چالش اصلی در محاسبه یا بهینه‌سازی مستقیم $p_{\theta}(X)$ در عمل چیست؟

(ج) از آنجا که محاسبه‌ی $p_{\theta}(X)$ عملی نیست، یک تقریب برای آن پیشنهاد دهید. راه‌نمایی: سعی کنید درست‌نمایی حاشیه‌ای را به صورت امید ریاضی بیان کنید.

(الف) (ب) (ج)

$$p_{\theta}(X) = \int p_{\theta}(X, Z) p(Z) dZ$$

طبق Bayes

$$p(X, Z) = p(X | Z) p(Z)$$

$$\hookrightarrow p_{\theta}(X) = \int p_{\theta}(X | Z) p_{\theta}(Z) dZ \Rightarrow \text{معمولاً به دلیل مشکل انتگرال‌گیری}$$

محاسبه مستقیم، جواب $p_{\theta}(X | Z)$ چون به ساده‌ترین شکل ممکن محاسبه می‌شود، روابط بین آنها؟ صورت غیرخطی

$$\mu_{\theta} = \text{NN}_{\alpha}(Z) \quad \text{و} \quad \Sigma_{\theta}(Z) = \text{diag}(\sigma_{\theta}(Z))$$

این محاسبه که مقدار Prior غیرممکن است.

$$p_{\theta}(X) = \int p_{\theta}(X | Z) p_{\theta}(Z) dZ \quad \left(\begin{array}{l} \text{داشته} \\ \text{است} \end{array} \right) \quad p_{\theta}(X) = \mathbb{E}_{Z \sim p_{\theta}(Z)} [p_{\theta}(X | Z)] \quad (8)$$

$$\rightarrow \mathbb{E}_{Z \sim p_{\theta}(Z)} [f(Z)] = \int f(Z) p_{\theta}(Z) dZ \quad \text{از طرفی مقدار انتگرال}$$

چگونه با توجه به این، پارامترهای Decoder را طوری Optimize کنیم که امید ریاضی Likelihood را به $\mathbb{E}_{Z \sim p_{\theta}(Z)} [p_{\theta}(X | Z)]$ برابر داده‌های واقعی زبانه‌ساز کنیم.

گام ۲: کاهش واریانس با Importance Sampling

چالش اصلی در برآورد $p_\theta(X)$ از طریق نمونه‌گیری، واریانس بالا است، زیرا نمونه‌های Z ممکن است از نواحی‌ای بیایند که به داده‌ی مشاهده‌شده‌ی X ارتباطی ندارند.
(الف) برای حل این مسئله، از importance sampling استفاده می‌کنیم. $p_\theta(X)$ را با استفاده از یک توزیع پیشنهادی $q(Z)$ بازنویسی کنید.
(ب) یک انتخاب شهودی برای توزیع پیشنهادی $q(Z)$ معرفی کنید.

اول تعریف مسئله، ما می‌خواهیم $p_\theta(X)$ را با استفاده از یک توزیع $q(Z)$ (که به عنوان Prior نامیده می‌شود) بسازیم. $p_\theta(X)$ احتمال واقعی است، اما $q(Z)$ احتمال پیشنهادی است. $p_\theta(X)$

در اینجا $q(Z)$ یک توزیع ساده‌تر است (مثلاً $q(Z) = \mathcal{N}(0, I)$) و $p_\theta(X)$ یک توزیع پیچیده‌تر است. ما می‌خواهیم $p_\theta(X)$ را با استفاده از $q(Z)$ بسازیم. $p_\theta(X)$ احتمال واقعی است، اما $q(Z)$ احتمال پیشنهادی است. $p_\theta(X)$

$$p_\theta(X) = \int p_\theta(X|z) p(z) dz \quad \Rightarrow \quad p_\theta(X) = \int p_\theta(X|z) \frac{p(z)}{q(z)} q(z) dz$$

(ب) فرض کن دنبال آدم قدبلند در یک شهر هستی. در حالت قبلی latent space ما میشد کل افراد شهر، که خوب با ۱۰۰ تا سکپل رندوم احتمال اینکه به یک توزیع خوب برای $p(X)$ برسی خیلی کم بود، اما اگر بری جلوی باشگاه بسکتبال نمونه‌گیری، احتمال قدبلند بودن افراد خیلی بیشتره پس یک $q(Z)$ ای میایم تعریف میکنیم که بیانگر اون فضای خاص از $p(Z)$ هستش. بقیشم که دیگه رابطست.

گام ۳: از Likelihood به ELBO

برای توجیه انتخاب توزیع پیشنهادی (Proposal Distribution)، دوباره به تخمین تابع هدف $p_\theta(X)$ بازمی‌گردیم.
(الف) چرا در یادگیری ماشین معمولاً با $\log p_\theta(X)$ کار می‌کنیم و نه با خود $p_\theta(X)$ ؟
(ب) چرا نمی‌توانیم $\log p_\theta(X)$ را مستقیماً برآورد کنیم؟ با استفاده از Jensen's inequality یک کران پایین برای آن استخراج کنید (این کران به عنوان Evidence Lower Bound یا ELBO شناخته می‌شود).
(ج) آیا بیشینه کردن این کران پایین در حین آموزش به‌تنهایی کافی است؟ چه مشکلاتی ممکن است ایجاد شود؟
(د) تفاضل بین $\log p_\theta(X)$ و کران پایین استخراج‌شده چیست؟ راهنمایی: این فاصله را به صورت KL divergence بنویسید.

$$\prod_i p_\theta(x_i) \Rightarrow \sum_i p_\theta(x_i)$$

(ب) با توجه به توضیح داده شده، چرا $\log p_\theta(X)$ را مستقیماً برآورد نمی‌کنیم؟

$$p_\theta(X) = \mathbb{E}_{z \sim q} \left[\frac{p_\theta(X, z)}{q(z|X)} \right]$$

$\log(P_\theta(X)) = \log \mathbb{E}_{q_\phi(z|X)} \left[\frac{P_\theta(X, z)}{q_\phi(z|X)} \right]$

$\left(\log x \right)' = -\frac{1}{x^2} < 0$

Jensen's Inequality
 Concave

$\log \mathbb{E}[Y] \geq \mathbb{E}[\log(Y)]$

$\mathbb{E}_{q_\phi(z|X)} \left[\log \left(\frac{P_\theta(X, z)}{q_\phi(z|X)} \right) \right]$

ELBO

$\mathcal{L}_{ELBO} \leq \log P_\theta(X) \Rightarrow \text{Evidence Lower Bound}$

$ELBO = \mathbb{E}_{q_\phi(z|X)} \left[\underbrace{\log P_\theta(X|z)}_{\text{Reconstruction term}} + \underbrace{\log P(z) - \log q_\phi(z|X)}_{D_{KL}} \right]$

$P(X, z) = P(X|z)P(z)$

Regularization term

Encoder, اور پوزیبل انٹرنیٹ
 Prior اور بالائی

Decoder, باہر نکالنا، z، x (خوبیہ)

کثرت

$ELBO = \mathbb{E}_{q_\phi(z|X)} [\log P_\theta(X|z)] - D_{KL}(q_\phi(z|X) || P(z))$

چ) مثال $ELBO$: فرضاً باینده که ما یک پارامتر θ داریم و $P_{\theta}(X)$ هست، اینو معکوس می‌کنیم و $P_{\theta}(Z|X)$ می‌کنیم. مقدار بالاییه، اگر تعریف می‌کنیم $P_{KL} \rightarrow$ که تپ بین $ELBO$ و $P_{\theta}(X)$ می‌باشد $\rightarrow$ خوب تعریف نخواهیم داشت.

د) بجای این که صحت (چ) توضیح داده شد $\rightarrow$ ؟ ما یک ترم دوم P_{KL} و $ELBO$ هست P_{KL} هست $ELBO$ طبقاً به KL Bound

$$P_{\theta}(Z|X) = \frac{P_{\theta}(Z) P_{\theta}(X|Z)}{P_{\theta}(X)}$$

عکساً محاسبه

ما یک مدل می‌سازیم Encoder $P_{\theta}(Z|X)$ با μ

و σ را تولید می‌کنیم

گام ۴: پارامتری کردن و بهینه‌سازی Posterior Approximation

تا اینجا انتخاب توزیع پیشنهادی را توجیه کردیم، اما با یک چالش جدید مواجه هستیم: $p_{\theta}(Z|X)$ واقعی posterior. بنابراین محاسبه است. بنابراین نمی‌توانیم مستقیماً KL divergence را کمینه کنیم. برای رفع این مشکل باید فرم توزیع تقریبی $q(Z)$ را مشخص کنیم. یک انتخاب رایج، توزیع گاوسی است:

$$q_{\lambda}(Z) = \mathcal{N}(Z | \mu, \sigma^2 I), \quad \lambda = \{\mu, \sigma^2\}$$

(الف) چگونه می‌توان KL divergence را به صورت غیرمستقیم کمینه کرد؟ راهنمایی: به گرادین $\nabla_{\lambda} \log p_{\theta}(X)$ فکر کنید.

(ب) گرادین $\nabla_{\theta} ELBO$ و تخمین Monte Carlo آن را محاسبه کنید.

(ج) آیا می‌توانید $\nabla_{\lambda} ELBO$ را نیز محاسبه کنید؟ چه چالش‌هایی در هنگام تخمین این گرادین با نمونه‌گیری Monte Carlo وجود دارد و چگونه می‌توان آن‌ها را حل کرد؟

راهنمایی: بررسی کنید چگونه می‌توان نمونه‌گیری $q_{\lambda}(Z) \sim Z$ را طوری نوشت که تصادفی بودن از پارامترهای λ جدا شود.

ب) باید نزدیک بودن $q_{\lambda}(Z)$ و Posterior $P_{\theta}(Z|X)$ را $D_{KL}(q_{\lambda}(Z) || P_{\theta}(Z|X))$ بسنجیم.

ما $P_{\theta}(Z|X)$ عکساً محاسبه می‌کنیم، اما از طرفی قدر ما $\min - \max$ داریم.

$$ELBO = \mathbb{E}[\log P_{\theta}(X|Z)] - D_{KL} \Rightarrow \text{loss} = -ELBO$$

$\max_x$ و $\min_z$ را می‌توانیم بنویسیم

$\text{loss} = -\mathbb{E}[\log P_{\theta}(X|Z)] + D_{KL}$
 Reconstruction loss KL Divergence

$$\text{ELBO} = \mathbb{E}_{z \sim q_\phi(z|x)} [\log p_\theta(x|z)] - \underbrace{D_{KL}(q_\phi(z|x) \| p(z))}_{\text{دانش}} : \text{برابر ELBO داشته باشیم}$$

$$\nabla_\theta \text{Loss} = \mathbb{E}_{z \sim q_\phi(z)} [\nabla_\theta \log p_\theta(x, z)] \quad \leftarrow \text{نسبت به } \theta \text{ (در مشتق) برابر}$$

$$\nabla_\theta \text{Loss} \approx \frac{1}{K} \sum_{k=1}^K \nabla_\theta \log p_\theta(x, z^{(k)})$$

! Monte Carlo

معنی 1. K Sample ، Decoder ، نسبت به θ مشتق می‌گیریم
 $p_\theta(x, z^{(k)})$

2. $\lambda = \mu + \sigma \epsilon$ برابر با حالت ما ، ϵ حالت ما ، ϵ حالت ما

مشتق عنصر به عنصر ، $\lambda = \mu + \sigma \epsilon$ ، ϵ از توزیع $N(0, 1)$ می‌گیریم

$$\ell = \mathbb{E}_{\epsilon \in N(0, 1)} [\log p_\theta(x, z_\lambda(\epsilon)) - \log q_\lambda(z_\lambda(\epsilon))] \quad \leftarrow \text{(مشتق بازنشانه می‌گیریم)}$$

$$\nabla_\lambda \ell = \mathbb{E}_\epsilon [\nabla_\lambda (\log p_\theta(x, z_\lambda(\epsilon)) - \log q_\lambda(z_\lambda(\epsilon)))]$$

در واقع ما randomness رو از یک Gaussian استاندارد ϵ می‌گیریم، بعد با scale σ و با shift μ می‌کنیم تا نمونه‌ای از توزیع latent مورد نظر بسازیم.

$$\nabla_\lambda \text{Loss} \approx \frac{1}{K} \sum_{k=1}^K \nabla_\lambda [\log p_\theta(x, z^{(k)}) - \log q_\lambda(z^{(k)})] \quad \leftarrow \text{مشتق بازنشانه می‌گیریم}$$

$$z^{(k)} = \mu + \sigma \epsilon^{(k)} \quad \rightarrow \text{جزء ما دخی}$$

تمام محاسبات قبلی بر اساس یک نمونه داده انجام شدند. اما اگر بخواهیم $\log p_{\theta}(X)$ را روی کل مجموعه داده بیشینه کنیم، چه تغییری ایجاد می‌شود؟

$$\frac{1}{B} \sum_{i=1}^B e(x^{(i)})$$

برابر θ با بر دور تمام نمونه ها مشترک باشد، چون نسبت خوب بود برابر تمام نمونه ها میگیریم
 $P_0(x|z)$ به gradient دوری dataset جمع یا Average میگیریم

(پ) ۵
دایق حالت: ۴ جابر دینکر ۲ برابر صفت ۹
۵
۱
۲
۳
۴
۵
۶
۷
۸
۹
۱۰
۱۱
۱۲
۱۳
۱۴
۱۵
۱۶
۱۷
۱۸
۱۹
۲۰
۲۱
۲۲
۲۳
۲۴
۲۵
۲۶
۲۷
۲۸
۲۹
۳۰
۳۱
۳۲
۳۳
۳۴
۳۵
۳۶
۳۷
۳۸
۳۹
۴۰
۴۱
۴۲
۴۳
۴۴
۴۵
۴۶
۴۷
۴۸
۴۹
۵۰
۵۱
۵۲
۵۳
۵۴
۵۵
۵۶
۵۷
۵۸
۵۹
۶۰
۶۱
۶۲
۶۳
۶۴
۶۵
۶۶
۶۷
۶۸
۶۹
۷۰
۷۱
۷۲
۷۳
۷۴
۷۵
۷۶
۷۷
۷۸
۷۹
۸۰
۸۱
۸۲
۸۳
۸۴
۸۵
۸۶
۸۷
۸۸
۸۹
۹۰
۹۱
۹۲
۹۳
۹۴
۹۵
۹۶
۹۷
۹۸
۹۹
۱۰۰
۱۰۱
۱۰۲
۱۰۳
۱۰۴
۱۰۵
۱۰۶
۱۰۷
۱۰۸
۱۰۹
۱۱۰
۱۱۱
۱۱۲
۱۱۳
۱۱۴
۱۱۵
۱۱۶
۱۱۷
۱۱۸
۱۱۹
۱۲۰
۱۲۱
۱۲۲
۱۲۳
۱۲۴
۱۲۵
۱۲۶
۱۲۷
۱۲۸
۱۲۹
۱۳۰
۱۳۱
۱۳۲
۱۳۳
۱۳۴
۱۳۵
۱۳۶
۱۳۷
۱۳۸
۱۳۹
۱۴۰
۱۴۱
۱۴۲
۱۴۳
۱۴۴
۱۴۵
۱۴۶
۱۴۷
۱۴۸
۱۴۹
۱۵۰
۱۵۱
۱۵۲
۱۵۳
۱۵۴
۱۵۵
۱۵۶
۱۵۷
۱۵۸
۱۵۹
۱۶۰
۱۶۱
۱۶۲
۱۶۳
۱۶۴
۱۶۵
۱۶۶
۱۶۷
۱۶۸
۱۶۹
۱۷۰
۱۷۱
۱۷۲
۱۷۳
۱۷۴
۱۷۵
۱۷۶
۱۷۷
۱۷۸
۱۷۹
۱۸۰
۱۸۱
۱۸۲
۱۸۳
۱۸۴
۱۸۵
۱۸۶
۱۸۷
۱۸۸
۱۸۹
۱۹۰
۱۹۱
۱۹۲
۱۹۳
۱۹۴
۱۹۵
۱۹۶
۱۹۷
۱۹۸
۱۹۹
۲۰۰
۲۰۱
۲۰۲
۲۰۳
۲۰۴
۲۰۵
۲۰۶
۲۰۷
۲۰۸
۲۰۹
۲۱۰
۲۱۱
۲۱۲
۲۱۳
۲۱۴
۲۱۵
۲۱۶
۲۱۷
۲۱۸
۲۱۹
۲۲۰
۲۲۱
۲۲۲
۲۲۳
۲۲۴
۲۲۵
۲۲۶
۲۲۷
۲۲۸
۲۲۹
۲۳۰
۲۳۱
۲۳۲
۲۳۳
۲۳۴
۲۳۵
۲۳۶
۲۳۷
۲۳۸
۲۳۹
۲۴۰
۲۴۱
۲۴۲
۲۴۳
۲۴۴
۲۴۵
۲۴۶
۲۴۷
۲۴۸
۲۴۹
۲۵۰
۲۵۱
۲۵۲
۲۵۳
۲۵۴
۲۵۵
۲۵۶
۲۵۷
۲۵۸
۲۵۹
۲۶۰
۲۶۱
۲۶۲
۲۶۳
۲۶۴
۲۶۵
۲۶۶
۲۶۷
۲۶۸
۲۶۹
۲۷۰
۲۷۱
۲۷۲
۲۷۳
۲۷۴
۲۷۵
۲۷۶
۲۷۷
۲۷۸
۲۷۹
۲۸۰
۲۸۱
۲۸۲
۲۸۳
۲۸۴
۲۸۵
۲۸۶
۲۸۷
۲۸۸
۲۸۹
۲۹۰
۲۹۱
۲۹۲
۲۹۳
۲۹۴
۲۹۵
۲۹۶
۲۹۷
۲۹۸
۲۹۹
۳۰۰
۳۰۱
۳۰۲
۳۰۳
۳۰۴
۳۰۵
۳۰۶
۳۰۷
۳۰۸
۳۰۹
۳۱۰
۳۱۱
۳۱۲
۳۱۳
۳۱۴
۳۱۵
۳۱۶
۳۱۷
۳۱۸
۳۱۹
۳۲۰
۳۲۱
۳۲۲
۳۲۳
۳۲۴
۳۲۵
۳۲۶
۳۲۷
۳۲۸
۳۲۹
۳۳۰
۳۳۱
۳۳۲
۳۳۳
۳۳۴
۳۳۵
۳۳۶
۳۳۷
۳۳۸
۳۳۹
۳۴۰
۳۴۱
۳۴۲
۳۴۳
۳۴۴
۳۴۵
۳۴۶
۳۴۷
۳۴۸
۳۴۹
۳۵۰
۳۵۱
۳۵۲
۳۵۳
۳۵۴
۳۵۵
۳۵۶
۳۵۷
۳۵۸
۳۵۹
۳۶۰
۳۶۱
۳۶۲
۳۶۳
۳۶۴
۳۶۵
۳۶۶
۳۶۷
۳۶۸
۳۶۹
۳۷۰
۳۷۱
۳۷۲
۳۷۳
۳۷۴
۳۷۵
۳۷۶
۳۷۷
۳۷۸
۳۷۹
۳۸۰
۳۸۱
۳۸۲
۳۸۳
۳۸۴
۳۸۵
۳۸۶
۳۸۷
۳۸۸
۳۸۹
۳۹۰
۳۹۱
۳۹۲
۳۹۳
۳۹۴
۳۹۵
۳۹۶
۳۹۷
۳۹۸
۳۹۹
۴۰۰
۴۰۱
۴۰۲
۴۰۳
۴۰۴
۴۰۵
۴۰۶
۴۰۷
۴۰۸
۴۰۹
۴۱۰
۴۱۱
۴۱۲
۴۱۳
۴۱۴
۴۱۵
۴۱۶
۴۱۷
۴۱۸
۴۱۹
۴۲۰
۴۲۱
۴۲۲
۴۲۳
۴۲۴
۴۲۵
۴۲۶
۴۲۷
۴۲۸
۴۲۹
۴۳۰
۴۳۱
۴۳۲
۴۳۳
۴۳۴
۴۳۵
۴۳۶
۴۳۷
۴۳۸
۴۳۹
۴۴۰
۴۴۱
۴۴۲
۴۴۳
۴۴۴
۴۴۵
۴۴۶
۴۴۷
۴۴۸
۴۴۹
۴۵۰
۴۵۱
۴۵۲
۴۵۳
۴۵۴
۴۵۵
۴۵۶
۴۵۷
۴۵۸
۴۵۹
۴۶۰
۴۶۱
۴۶۲
۴۶۳
۴۶۴
۴۶۵
۴۶۶
۴۶۷
۴۶۸
۴۶۹
۴۷۰
۴۷۱
۴۷۲
۴۷۳
۴۷۴
۴۷۵
۴۷۶
۴۷۷
۴۷۸
۴۷۹
۴۸۰
۴۸۱
۴۸۲
۴۸۳
۴۸۴
۴۸۵
۴۸۶
۴۸۷
۴۸۸
۴۸۹
۴۹۰
۴۹۱
۴۹۲
۴۹۳
۴۹۴
۴۹۵
۴۹۶
۴۹۷
۴۹۸
۴۹۹
۵۰۰
۵۰۱
۵۰۲
۵۰۳
۵۰۴
۵۰۵
۵۰۶
۵۰۷
۵۰۸
۵۰۹
۵۱۰
۵۱۱
۵۱۲
۵۱۳
۵۱۴
۵۱۵
۵۱۶
۵۱۷
۵۱۸
۵۱۹
۵۲۰
۵۲۱
۵۲۲
۵۲۳
۵۲۴
۵۲۵
۵۲۶
۵۲۷
۵۲۸
۵۲۹
۵۳۰
۵۳۱
۵۳۲
۵۳۳
۵۳۴
۵

معنی؟ بازتاب از لحاظ معنی حرف هکتار در هر داده ها این است که مسئله را با داده ها و معنی داده و در هر مسئله با نام مسئله latent space و map به

گام ۶: ELBO نهایی و آموزش مدل

اکنون که کل هدف VAE استخراج شده است، فرآیند آموزش را توصیف کنید.
(الف) نشان دهید که ELBO را می‌توان به صورت زیر نوشت و مفهوم هر ترم از عبارات را توضیح دهید:

$$\mathbb{E}_{z \sim q_\phi(z|x)} [\log p_\theta(x|z)] - \text{KL}(q_\phi(z|x) \| p_\theta(z))$$

(ب) حال که مدل VAE کامل شده است، الگوریتم آموزش آن را بنویسید. در این الگوریتم نشان دهید:

• چگونه از encoder و decoder استفاده می‌شود؟

• نمونه‌گیری چگونه انجام می‌شود؟

• تابع هدف چگونه بهینه می‌شود؟

(الف) به نظر می‌رسد هر دو ترم هم موضوع داده‌هاست. $\log p_\theta(x|z)$ باید $\log p_\theta(x|z)$ باشد و $\text{KL}(q_\phi(z|x) \| p_\theta(z))$ باید $\text{KL}(q_\phi(z|x) \| p_\theta(z))$ باشد. Reconstruction هست که حاصله از بالا باشد (max) و $\log p_\theta(x|z)$ باید از پایین (min) باشد.

۱) $x \rightarrow \text{Encoder} \rightarrow \mu_\phi(x), \sigma_\phi(x) \rightarrow \text{Sample } \epsilon \sim N(0, I) \rightarrow z = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon \rightarrow \text{Decoder} \rightarrow p_\theta(x|z) \rightarrow \text{ELBO} \rightarrow \text{Back Propagation} \rightarrow \text{Update } \phi, \theta$

از Encoder بر روی x به $\mu_\phi(x)$ و $\sigma_\phi(x)$ می‌رسیم. $q_\phi(z|x) = N(z | \mu_\phi(x), \sigma_\phi^2(x)I)$. $z = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon$ که $\epsilon \sim q_\phi(z|x)$ می‌باشد. Decoder به ما می‌دهد $p_\theta(x|z)$ که ما می‌خواهیم آن را max کنیم.

تابع هدف ما $\text{loss} = \mathbb{E} [\log p_\theta(x|z) - \text{KL}(q_\phi(z|x) \| p_\theta(z))]$ است. ما می‌خواهیم این تابع را minimize کنیم. $-\text{loss} = -(\text{reconstruction loss}) + (\text{KL loss})$

پرسش ۲. Hierarchical VAE (۲۰ نمره)

یک مدل Hierarchical Variational Autoencoder (HVAE) با دو لایه را در نظر بگیرید که دارای متغیرهای نهان z_1 و z_2 است، به طوری که z_1 لایه پایین و z_2 لایه بالا می باشد. مدل مولد به صورت زیر تعریف می شود:

$$p(x, z_1, z_2) = p(x | z_1) p(z_1 | z_2) p(z_2)$$

Decoder →

تقریب پسین (Encoder) به صورت زیر تعریف می شود:

$$q(z_1, z_2 | x) = q(z_1 | x) q(z_2 | z_1)$$

←

(الف)

کران پایین شواهد (ELBO) را به صورت $L(x)$ برای این مدل HVAE استخراج کنید. به شکل امید ریاضی روی توزیع تقریبی $q(z_1 | x) q(z_2 | z_1)$ است که از ۳ بخش تشکیل شده است، لگاریتم درست نمایی و KL divergence بین توزیع های مربوطه.

Reconstruction / log-likelihood term

$$\text{Loss}(x) = \mathbb{E} \left[\log \frac{p(x, z_1, z_2)}{q(z_1, z_2 | x)} \right]$$

$$\text{Loss}(x) = \mathbb{E} \left[\underbrace{\log p(x | z_1)}_{\text{بخش اول}} + \underbrace{\log p(z_1 | z_2)}_{\text{بخش سوم}} + \underbrace{\log p(z_2)}_{\text{بخش دوم}} - \underbrace{\log q(z_1 | x)}_{\text{بخش اول}} - \underbrace{\log q(z_2 | z_1)}_{\text{بخش دوم}} \right]$$

$\mathbb{E} \left[\log \frac{p(z_2)}{q(z_2 | z_1)} \right]$ ← توزیع z_2 بر روی z_1 به دست آمده از Prior z_2 توسط Decoder

$\mathbb{E} \left[\log \frac{p(z_1 | z_2)}{q(z_1 | x)} \right]$ ← توزیع z_1 بر روی x به دست آمده از Prior z_1 توسط Decoder

بخش سوم: $\mathbb{E} \left[\log \frac{p(z_1 | z_2)}{q(z_1 | x)} \right]$ ← توزیع z_1 بر روی x به دست آمده از Prior z_1 توسط Decoder

ما به توزیع z_2 به دست آمده از Encoder توسط ورودی x نزدیک می شویم.

$$\text{Loss}(x) = \mathbb{E}_{q(z_1 | x)} \left[\log p(x | z_1) \right] - \mathbb{E} \left[\text{KL} (q(z_1 | x) || p(z_1 | z_2)) \right] - \mathbb{E}_{q(z_1 | x)} \left[\text{KL} (q(z_2 | z_1) || p(z_2)) \right]$$

پرسش ۳. GAN (۲۰ نمره)

در این سوال، قصد داریم بین مسئله‌ی "تشخیص داده واقعی و داده تولید شده" و مسئله‌ی "فاصله توزیع تصاویر واقعی و تصاویر تولید شده" ارتباطی برقرار کنیم. توزیع تصاویر واقعی را با P_d و توزیع تصاویر تولید شده را با P_g نشان می‌دهیم. همچنین توزیع P که داده‌ای تصادفی را به ما می‌دهد، به صورت زیر تعریف می‌شود:

$$P(x) = 0.5P_g(x) + 0.5P_d(x)$$

Nash عادل

بنابراین، هر داده با احتمال مساوی از یکی از دو توزیع P_g یا P_d می‌آید. حال، مجموعه‌ای از نمونه‌ها (x, y) تشکیل می‌دهیم، به این ترتیب که:

• x را از توزیع P نمونه‌گیری می‌کنیم.

• اگر x از توزیع واقعی P_d باشد، برچسب آن را $y = 1$ قرار می‌دهیم، و در غیر این صورت (اگر از P_g آمده باشد) $y = -1$.

اکنون، $\mathcal{D}$ را مجموعه تمامی تمایزدهنده‌ها در نظر می‌گیریم. هدف ما یافتن بهترین تمایزدهنده در این مجموعه است. فرض می‌کنیم این مجموعه هیچ محدودیتی ندارد و تمایزدهنده‌ها دارای ظرفیت نامحدود هستند. منظور از ظرفیت نامحدود این است به ازای هر تابع $y(x)$ دلخواه، تابعی در $\mathcal{D}$ با چنین رفتاری وجود دارد. بنابراین اگر نقطه بهینه تابع برای هر x را بیابید می‌توانید از وجود تمایزدهنده‌ای با این اتخاذها مطمئن باشید. بهترین تمایزدهنده D در مجموعه $\mathcal{D}$ تابع هزینه زیر را کمینه می‌کند:

$$R_l(D) = \mathbb{E}_{(x,y) \sim P}[l(yD(x))]$$

در اینجا، هزینه به صورت امیدریاضی روی داده‌های (x, y) تعریف شده است. اکنون مقدار بهینه این تابع را تعریف می‌کنیم:

$$R_l(\mathcal{D}) = \inf_{D \in \mathcal{D}} R_l(D)$$

بخش اول

ابتدا امیدریاضی موجود در رابطه بالا را به صورت انتگرال روی توزیع x بازنویسی کنید. عبارت شما باید مشابه فرم زیر باشد:

$$\inf_{D \in \mathcal{D}} \left\{ \int ([\text{sth}] p_d(x) + [\text{sth}] p_g(x)) dx \right\}$$

سپس با توجه به ظرفیت نامحدود مجموعه $\mathcal{D}$ ، بهینه عبارت بدست آمده را از روی بهینه نقطه‌ای حساب کنید. توجه کنید که ظرفیت نامحدود چه تاثیری روی اینفیم دارد. نهایتاً با جاگذاری بهینه و جابه‌جایی عبارت‌ها نشان دهید که این مقدار برابر است با:

$$-\frac{1}{2} \int f \left(\frac{p_d(x)}{p_g(x)} \right) p_g(x) dx$$

توجه کنید که باید تابع f را به دست آورید. پس از رسیدن به این رابطه، بررسی کنید که تابع f به دست آمده بر حسب ورودی خود، محدب و نزولی باشد. ازین به بعد عبارت بالا را به استفاده از مفهوم واگرایی f به صورت

$$-\frac{1}{2} \mathbb{I}_f(\mathbb{P}_d, \mathbb{P}_g)$$

نمایش می‌دهیم.

hah

$$R_c(D) = \frac{1}{2} \int e(D(x)) P_d(x) dx + \frac{1}{2} \int e(-D(x)) P_g(x) dx$$

discriminator $\rightarrow +1$ Generator

$$\Rightarrow R_c(D) = \frac{1}{2} \int [e(D(x)) P_d(x) + e(-D(x)) P_g(x)] dx$$

[sth]

حالت بهینه $\hookrightarrow R_c^*(D) = \inf_{D \in \mathcal{D}} R_c(D)$

$$Q = D(\alpha)$$

خالق السیر $P_g(a)$

$r \rightarrow -f(r) = \inf [r \ell(u) + \ell(u)]$

$$1 \Rightarrow R_e^* = -\frac{1}{2} \int \left(\frac{P_d(x)}{P_g(x)} \right) P_g(x) dx$$

$$\Rightarrow \bar{I}_f(P_d \circ P_g) = \int P_g(x) f\left(\frac{P_d(x)}{P_g(x)}\right) dx \Rightarrow \bar{K}_e^* = -\frac{1}{2} \bar{I}_f(P_d \circ P_g)$$

کتابچہ و عرب یا Concave

در بخش قبل، نشان دادیم که این مسئله معادل کمینه کردن یک واگرایی بین دو توزیع است. اکنون می‌خواهیم بررسی کنیم که با انتخاب توابع هزینه مختلف $l(x)$ ، چه نوع واگرایی‌هایی حاصل می‌شوند. برای هر تابع هزینه $l(x)$:

۱. ابتدا محدب بودن و یکنوایی تابع f متناظر را بررسی کنید.

۲. سپس، تمایزدهنده بهینه، تابع f ، و واگرایی متناظر را استخراج کنید.

حالت‌های مورد بررسی:

• الف) $l(x) = \mathbb{I}(x \leq 0)$

• ب) $l(x) = (1 - x)^2$

• ج) $l(x) = \log(1 + e^{-x})$

راهنمایی: واگرایی‌های متناظر توابع هزینه به صورت نامرتب در ادامه آمده‌اند. می‌توانید جهت بررسی درستی حل خود از این بخش استفاده کنید.

• $R(D) = \frac{1}{2}(1 - \mathbb{I}_{TV}(\mathbb{P}_d, \mathbb{P}_g))$ که منظور از TV تابع Total Variation است.

• $R(D) = \log 2 - \mathbb{I}_{JS}(\mathbb{P}_d, \mathbb{P}_g)$ که منظور از JS تابع Jensen Shannon است.

• $R(D) = 1 - \mathbb{I}_g(\mathbb{P}_d, \mathbb{P}_g)$ که منظور از g تابع $\frac{-4t}{t+1}$ است.

از بخش قبل داریم

$$f(r) = \inf [r l(u) + l(-u)] \rightarrow l(u) = \mathbb{I}(u \leq 0) \quad \text{الف)}$$

که می‌توانیم این را به این شکل در نظر بگیریم: $u > 0$ داده را r real تشخیص می‌دهد

و اگر $u < 0$ take می‌کند

$$r \mathbb{I}(u \leq 0) + \mathbb{I}(u > 0) \rightarrow \begin{cases} u > 0 \Rightarrow 0 + \mathbb{I} = \mathbb{I} \\ u < 0 \Rightarrow r \mathbb{I} + 0 = r \end{cases}$$

می‌توانیم به این شکل در نظر بگیریم

$$f(r) = -\min(r, 1) \quad \text{اگر } r > 1 \text{ که } k=r$$

واقعاً بدون سبزه و اگر $r < 1$ که r take می‌کند

$$D^*(x) = \text{sig}(P_d(x) - P_g(x))$$

از طرف

$$R^* = \frac{1}{2} \int \min(P_d(x), P_g(x)) dx = \frac{1}{2} [1 - TV(P_d, P_g)]$$

$$\text{Total Variation} \Rightarrow \int \min(P_d, P_g) dx = \frac{1}{2} \left[\int P_d(x) dx + \int P_g(x) dx - \int |P_d(x) - P_g(x)| dx \right]$$

$$R(D) = \frac{1}{2} \int e(D(x)) P_d(x) dx + \frac{1}{2} \int e(-D(x)) P_g(x) dx$$

$$e(x) = (1-x)^2$$

(ب)

$$\Rightarrow R(D) = \frac{1}{2} \int (1-D(x))^2 P_d(x) dx + \frac{1}{2} \int (1+D(x))^2 P_g(x) dx$$

$$f(D) = \frac{1}{2} P_d(x) (1-D)^2 + \frac{1}{2} (1+D)^2 P_g(x)$$

$$\frac{\partial f(D)}{\partial D} = 0 \Rightarrow \frac{1}{2} (-2(1-D) P_d(x) + 2(1+D) P_g(x)) = 0$$

$$\Rightarrow -(1-D) P_d(x) + (1+D) P_g(x) = 0 \Rightarrow D(P_g(x) + P_d(x)) = P_d(x) - P_g(x)$$

$$\Rightarrow D^*(x) = \frac{P_d - P_g}{P_d + P_g}$$

$$R(D^*) = \frac{1}{2} \int P_d (1-D^*)^2 + P_g (1+D^*)^2 dx = \frac{1}{2} \int P_d \left(\frac{2P_g}{P_d + P_g} \right)^2 + P_g \left(\frac{2P_d}{P_d + P_g} \right)^2 dx$$

$$= 2 \int \frac{P_d P_g}{P_d + P_g} dx$$

$$R(D) = \frac{1}{2} \int e(D(x)) P_D(x) dx + \frac{1}{2} \int e(-D(x)) P_G(x) dx$$

(ج)

$$L(x) = \log(1 + e^{-x})$$

$$\Rightarrow R(D) = \frac{1}{2} \int \log(1 + e^{-D(x)}) P_D(x) dx + \frac{1}{2} \int \log(1 + e^{D(x)}) P_G(x) dx$$

$$f(D) = \frac{1}{2} P_D(x) \log(1 + e^{-D}) + \frac{1}{2} \log(1 + e^D) P_G(x)$$

$$\frac{d(\log(1 + e^{-D}))}{dD} = \frac{-e^{-D}}{1 + e^{-D}} \times \frac{e^D}{e^D} = \frac{-1}{1 + e^D}$$

$$\frac{d(\log(1 + e^D))}{dD} = \frac{e^D}{1 + e^D}$$

$$\Rightarrow \frac{\partial f}{\partial D} = 0 \Rightarrow \frac{1}{2} \left(\frac{1}{1 + e^D} \right) (-P_D(x) + e^D P_G(x)) = 0 \Rightarrow e^D = \frac{P_D(x)}{P_G(x)}$$

$$\Rightarrow D^* = \log_e \frac{P_D(x)}{P_G(x)}$$

$$R(D) \Rightarrow -\log^2 + JS(P_D \| P_G) \leadsto \min_e JS(P_D \| P_G) \quad \text{generator}$$

پرسش ۴. یادگیری تابع امتیاز در Diffusion (۲۰ نمره)

در اسلایدهای درس دیدیم که هدف اصلی ما یادگیری تابع امتیاز است. یک راه ساده برای رسیدن به این هدف، تعریف تابع هزینه‌ای بین مقدار حقیقی تابع امتیاز و خروجی شبکه عصبی است:

$$l_1(\theta) = \mathbb{E}_{q(x)} \left[\frac{1}{2} \|s_\theta(x) - \nabla_x \log q(x)\|_2^2 \right]$$

اما مشکل اینجاست که به $\nabla_x \log q(x)$ دسترسی نداریم. در ادامه یاد گرفتیم که اگر مدل بتواند نویز را تخمین بزند، می‌توان از آن برای تخمین تابع امتیاز استفاده کرد. قبل از پرداختن به آن، رابطه‌ای ساده‌تر را بررسی می‌کنیم.

بخش (الف): ساده‌سازی تابع هزینه در این بخش می‌خواهیم مقدار ناشناخته تابع امتیاز را از تابع هزینه حذف کنیم. با استفاده از انتگرال جز به جز و حذف بخش‌های مستقل از θ نشان دهید که:

$$l_1(\theta) = \mathbb{E}_{q(x)} \left[\frac{1}{2} \|s_\theta(x)\|_2^2 + \text{Tr}(\nabla_x s_\theta(x)) \right] + C_1$$

که C_1 مستقل از θ است. در اثبات خود فرض کنید که وقتی $x \rightarrow \infty$ داریم که $q(x)s_\theta(x) \rightarrow 0$. در پایان، توضیح دهید چرا این تابع هزینه در عمل ممکن است برای آموزش مناسب نباشد؟

$$\frac{1}{2} \|s_\theta(x) - \nabla_x \log q(x)\|^2 = \frac{1}{2} \|s_\theta(x)\|^2 - s_\theta(x)^T \nabla_x \log q(x) + \frac{1}{2} \|\nabla_x \log q(x)\|^2$$

مستقل از θ ← C_1
بخش مستقل
بخش وابسته

$$\mathbb{E}_q[-s_\theta(x)^T \nabla_x \log q(x)] \leadsto \text{دلمیر } \nabla_x \log q(x) = \frac{\nabla_x q(x)}{q(x)}$$

$$\Rightarrow q(x) \nabla_x \log q(x) = \nabla_x q(x) \Rightarrow \int s_\theta(x)^T \nabla_x q(x) dx$$

$$\Rightarrow \int f(x) g'(x) dx = f(x) g(x) - \int f'(x) g(x) dx$$

در اینجا $\int q(x) \nabla_x s_\theta(x) dx$

$\Rightarrow x \rightarrow \infty \Rightarrow q(x)s_\theta(x) = 0 \Rightarrow$ در اینجا

$$-\mathbb{E}_q[s_\theta(x)^T \nabla_x \log q(x)] \stackrel{\text{تبدیل}}{=} \mathbb{E}_q[\text{Tr}(\nabla_x s_\theta(x))]$$

$$\rightarrow \ell(\theta) = \mathbb{E}_q \left[\frac{1}{2} \|s_\theta(x)\|^2 + \text{Tr}(\nabla_x s_\theta(x)) \right] + C_1$$

بروز می‌دهد

بخش (ب): ارتباط با تخمین نویز اکنون هدف ما این است که نشان دهیم تابع هزینه بالا معادل با تابع هزینه‌ای است که بر اساس تخمین نویز تعریف می‌شود:

مشتق با دست

$$l_3(\theta) = \mathbb{E}_{x \sim q(x), \epsilon \sim \mathcal{N}(0, I)} \left[\frac{1}{2} \left\| s_\theta(\underbrace{x + \sigma \epsilon}_x) + \frac{\epsilon}{\sigma} \right\|^2 \right]$$

جفت داده سالم و نویزی را $(x, \tilde{x})$ می‌نامیم. طبق رابطه زیر، برای کرنل گاوسی داریم:

$$\frac{\partial \log q(\tilde{x}|x)}{\partial \tilde{x}} = \frac{1}{\sigma^2}(x - \tilde{x})$$

در نتیجه:

$$l_3(\theta) = \mathbb{E}_{q(x, \tilde{x})} \left[\frac{1}{2} \left\| s_\theta(\tilde{x}) - \frac{\partial \log q(\tilde{x}|x)}{\partial \tilde{x}} \right\|^2 \right]$$

ثابت کنید که:

$$l_3 = l + C$$

که C مستقل از θ است.

اگر نیاز به راهنمایی دارید، می‌توانید به پیوست مقاله زیر مراجعه کنید:

A Connection Between Score Matching and Denoising Autoencoders

اما سعی کنید مراحل اثبات را خودتان کامل نوشته و توضیح دهید.

$$l_3(\theta) = \mathbb{E} \left[\frac{1}{2} \left\| s_\theta(\tilde{x}) + \frac{\epsilon}{\sigma} \right\|^2 \right]$$

مستقل از θ → C

به جای یادگیری مستقیم score واقعی که غیرقابل محاسبه است، داده را نویزی می‌کنیم تا score توزیع Gaussian شرطی قابل محاسبه شود.

پرسش ۵. آیا فرض مارکوف در Diffusion الزامی است؟ (۲۰ نمره)

در ساختار فروارد دیفیوژن، فرض کردیم که:

$$q(\mathbf{x}_{1:T} | \mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1})$$

این فرض مارکوف باعث می‌شود که برای تولید، نیاز به انجام T مرحله به صورت ترتیبی داشته باشیم. برای درستی فرض گاوسی بودن می‌دانیم، T باید بزرگ باشد که باعث هزینه زمانی زیاد می‌شود. آیا می‌توانیم بدون فرض مارکوف بودن هم به همان توزیع حاشیه $q(\mathbf{x}_t | \mathbf{x}_0)$ برسیم؟
دقت کنید که در فرم تابع هدف (Objective) نهایی، یعنی:

$$L(\epsilon_\theta) := \sum_{t=1}^T \gamma_t \mathbb{E}_{\mathbf{x}_0 \sim q(\mathbf{x}_0), \epsilon_t \sim \mathcal{N}(0, \mathbf{I})} \left[\left\| \epsilon_\theta^{(t)} (\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon_t) - \epsilon_t \right\|_2^2 \right]$$

تنها این حاشیه تاثیر دارد و توزیع مشترک x_i ها تاثیری ندارد.
در مدل استاندارد، این مارجین به صورت زیر است:

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I})$$

بنابراین، می‌توان ساختاری غیرمارکوفی تعریف کرد که همین مارجین را تولید کند.
برای یک بردار $\sigma \in \mathbb{R}_{\geq 0}^T$ توزیع اینفرنس را به صورت زیر تعریف می‌کنیم:

$$q_\sigma(\mathbf{x}_{1:T} | \mathbf{x}_0) := q_\sigma(\mathbf{x}_T | \mathbf{x}_0) \prod_{t=2}^T q_\sigma(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$$

که در آن:

$$q_\sigma(\mathbf{x}_T | \mathbf{x}_0) = \mathcal{N}(\sqrt{\bar{\alpha}_T} \mathbf{x}_0, (1 - \bar{\alpha}_T) \mathbf{I})$$

و برای $t > 1$:

$$q_\sigma(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \mathcal{N} \left(\sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_{t-1} - \sigma_t^2} \cdot \frac{\mathbf{x}_t - \sqrt{\bar{\alpha}_t} \mathbf{x}_0}{\sqrt{1 - \bar{\alpha}_t}}, \sigma_t^2 \mathbf{I} \right)$$

الف) اثبات برابری مارجین‌ها با استفاده از خواص توزیع گاوسی و به کمک استقرا ثابت کنید:

$$q_\sigma(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I})$$

توجه کنید که فرایند فروارد ما دیگر مارکوف نیست، زیرا $\mathbf{x}_t$ به $\mathbf{x}_0$ نیز وابسته است:

$$q_\sigma(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0) = \frac{q_\sigma(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) q_\sigma(\mathbf{x}_t | \mathbf{x}_0)}{q_\sigma(\mathbf{x}_{t-1} | \mathbf{x}_0)}$$

مشاهده جالب: اگر $\sigma_t \rightarrow 0$ ، واریانس گاوسی به صفر میل می‌کند و $\mathbf{x}_{t-1}$ به صورت قطعی از $\mathbf{x}_t$ و $\mathbf{x}_0$ به دست می‌آید. بنابراین می‌توان فرآیند جبریشن را به یک فرآیند قطعی تبدیل کرد که تنها منبع تصادفی آن نویز اولیه $\mathbf{x}_T$ است.
این دیدگاه امکان نوعی تناظر بین فضای پنهان و خروجی را فراهم می‌کند، و دقت کنید که توزیع حاشیه‌ای که حاصل می‌شود همان توزیع مدل دیفیوژن تصادفی خواهد بود.

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0) q(\mathbf{x}_{t-1} | \mathbf{x}_0)}{q(\mathbf{x}_t | \mathbf{x}_0)}$$

$$q(\mathbf{x}_t | \mathbf{x}_0) = q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0) q(\mathbf{x}_{t-1} | \mathbf{x}_0)$$

$$\Rightarrow \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0) q(\mathbf{x}_{t-1} | \mathbf{x}_0)}{q(\mathbf{x}_t | \mathbf{x}_0)} \Rightarrow \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0)}{q(\mathbf{x}_t | \mathbf{x}_0)} \Rightarrow 1$$

هم گاوسی می‌شود

دری فرآیند forward و فرآیند مارکوف روی یک مدل reverse diffusion؟ مشکل ما فراموش کردن میل به یادگیری است.
در مدل مارکوف، $P(\mathbf{x}_{t-1} | \mathbf{x}_t)$ اونیروکال و forward مارکوف بالایی، می‌توانیم این مراحل را حاشیه کنیم.

مارکوف بودن به ما اجازه می دهد:

۱. نویز را مرحله به مرحله اضافه کنیم .

۲. reverse distribution یا Gaussian کنیم .

۳. denoising را به یک مسئله قابل یادگیری تبدیل کنیم .

اما هزینه T بزرگ است. یعنی sampling آهسته می شود. به همین دلیل روش هایی مثل:

• DDIM

• DPM-Solver

• Latent Diffusion

آمدند تا با تعداد step کمتر همان کیفیت را بدهند.

فرآیند جنریشن ابتدا با استفاده از عبارت زیر که مشابه مدل استاندارد است، نمونه ای نویزی ساخته و بدون دسترسی به x_0 نویز آن را تخمین می زنیم:

نویز ← سکیل با σ_t

$$x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, \mathbf{I})$$

با مدل تخمین نویز می توانیم نمونه ی بدون نویز را به صورت زیر بازسازی کنیم:

$$f_{\theta}^{(t)}(x_t) := \frac{x_t - \sqrt{1 - \alpha_t} \cdot \epsilon_{\theta}^{(t)}(x_t)}{\sqrt{\alpha_t}}$$

بنابراین ابتدا داریم که

$$p_{\theta}(x_T) = \mathcal{N}(0, \mathbf{I})$$

و پس از آن

$$p_{\theta}^{(t)}(x_{t-1} | x_t) = \begin{cases} \mathcal{N}(f_{\theta}^{(1)}(x_1), \sigma_1^2 \mathbf{I}) & t = 1 \\ q_{\sigma}(x_{t-1} | x_t, f_{\theta}^{(t)}(x_t)) & \text{غیر این صورت} \end{cases}$$

حال با این مدل جنریشن، آموزش به چه صورتی می شود؟ ابتدا دقت می کنیم که هدف آموزش مدل ما چه بود؟ مشابه قبل، ما به دنبال پارامترهایی هستیم که عبارت زیر اتخاذ شود.

$$\arg \max_{\theta} \mathbb{E}_{x_0 \sim q} [\log p_{\theta}(x_0)]$$

بنابراین می توان همان استدلال های مدل استاندارد را برای یافت تابع هزینه در این مدل نیز کرد.

(ب) تطابق تابع هدف (Objective) با دیفیوژن کلاسیک با تکرار مراحل ذکر شده در اسلایدهای درس و تحلیل ELBO نشان دهید که تابع هدف این مدل مولد با مدل بررسی شده در اسلایدها یکسان است (به جز یک ثابت مستقل از θ). در برابری فرض کنید که در تابع هدف مدل استاندارد تابع هزینه t های مختلف، ضریب برابری دارند.

پرسش: به نظر شما چگونه می توان از این نگاه برای کاهش زمان طولانی جنریشن استفاده کرد؟

هدف آموزش ما در اسلایدها آمده $\arg \max_{\theta} \mathbb{E}_{x_0 \sim q} [\log p_{\theta}(x_0)]$ بشود کرد likelihood داده

واژه هست استابست تر VAE به لحاظ جوره با صورت معتم امکان پذیرست از ELBO
السنده و کتنه $\mathbb{E}_{q(\phi)} \log p_{\theta}(x_0) \geq ELBO$

با supervised loss می توانیم $loss(\theta) = \mathbb{E} [\| \epsilon - \epsilon_{\theta}(x_t, t) \|^2]$ بسنجیم این تابع $loss(\theta)$ را می توانیم به عنوان supervised loss در نظر بگیریم

(پ) (1) روش DDIM بر بستر markov chain و تولید غیر deterministic. step 1
کدام، مترساق (2) latent : 8.8 بر هفت صفر (10) باید زیر هفت یک عدد کار کنیم
Diffusion

(3) تعریف هار؟ جزئیات DPM-solver و Euler Sampler و Heun Sampler