

پرسش ۱. DetailCLIP (۵۰ نمره)

معماری DetailCLIP که در شکل ۱ نمایش داده شده، برای وظایفی که نیازمند قطعه‌بندی دقیق تصویر هستند، طراحی شده است. برخلاف مدل‌های سنتی که ممکن است جزئیات ریز را نادیده بگیرند، این مدل با استفاده از سه تکنیک، دقت را حفظ کرده و در عین حال از نظر محاسباتی کم‌هزینه باقی می‌ماند.

۱. Patch-Level Self-Distillation

در این روش، بخش‌های کوچک‌تر تصویر (دانش‌آموزان) از بخش‌های بزرگ‌تر (معلمان) یاد می‌گیرند. این رویکرد به حفظ جزئیات کمک می‌کند که در غیر این صورت ممکن است از بین بروند. با تمرکز بر این تفاوت‌های ظریف، مدل از تقسیم‌بندی‌های اشتباهی که مدل‌های دیگر می‌کنند دور می‌ماند.


۲. حذف توکن (Attention-Based Token Removal)

این تکنیک مانند فیلتری برای داده‌ها عمل می‌کند. مدل تحلیل می‌کند که کدام بخش‌های تصویر اهمیت بیشتری دارد، برای مثال درک اهمیت شی داخل تصویر در برابر بک‌گراند تصور. این نه تنها سرعت تحلیل را افزایش می‌دهد بلکه با حذف نویز از مناطق غیرمهم، دقت را بهبود می‌بخشد.

۳. بازسازی در سطح پیکسل (Pixel-Level Reconstruction)

این روش برای افزایش وضوح تصویر به کار می‌رود. حتی هنگام کار با ورودی‌های با وضوح پایین، مدل می‌تواند خط‌های تیز و دقیقی را بازسازی کند. این ویژگی به‌ویژه برای اشکال پیچیده مانند خز حیوانات یا شاخ و برگ درختان ارزشمند است، جایی که لبه‌های دقیق برای تقسیم‌بندی دقیق ضروری هستند.

این روش‌ها با همدیگر همکاری می‌کنند تا مدل به دقت بالاتری برسد: Self-Distillation جزئیات ریز را حفظ می‌کند، حذف توکن پردازش را بهینه می‌کند، و بازسازی وضوح خروجی نهایی را دقیق‌تر می‌کند.



شکل ۱: با استفاده از معماری teacher-student، دو نمای مختلف از تصویر ورودی را پردازش کرده و مقادیر توجه (attention) را تولید می‌کند تا حذف توکن‌ها در مدل student را هدایت کند. سپس مدل student تصویر را با یک decoder vision بازسازی می‌کند، در حالی که هم‌زمان سه تابع هزینه شامل تابع طبقه‌بندی $(\mathcal{L}_{CLS})$ ، تابع patch $(\mathcal{L}_{Patch})$ ، و تابع بازسازی $(\mathcal{L}_{Rec})$ را بهینه می‌کند. همچنین تابع هزینه CLIP $(\mathcal{L}_{CLIP})$ به alignment میان انکودرهای تصویر و متن کمک می‌کند.

سؤالات:

۱. با توجه به پویایی teacher-student در یادگیری patch-level :

(آ) این رویکرد سلسله‌مراتبی چگونه به حفظ جزئیاتی از تصویر که ممکن است در غیر این صورت از بین بروند کمک می‌کند؟

(ب) مدل‌های دسته‌بندی سنتی چه محدودیت‌هایی دارند که این تکنیک به رفع آن‌ها کمک می‌کند؟

آ) در حلقه یادگیری در سطح Patch، Self-Distillation (نمایش می‌دهیم)، مدل CLIP یاد می‌گیرد که چگونه جزئیات را حفظ کند. [CLS] در این مرحله به عنوان یک توکن خاص عمل می‌کند و به حذف توکن‌های غیرمهم در مدل student و teacher کمک می‌کند. همچنین، این مدل به بازسازی تصویر کمک می‌کند و به این ترتیب، اطلاعات بیشتری را می‌تواند در سیستم‌های بعدی ارائه دهد.

ب) مدل‌های Classification سنتی برای تشخیص کلاس کلی تصویر بهینه می‌شوند و بنابراین ممکن است جزئیات محلی غیرضروری برای Classification را حذف کنند. این موضوع آنها را برای وظایف Dense Prediction مانند Segmentation ضعیف می‌کند. Patch-Level Self-Distillation با نظارت مستقیم روی Patch Representation ها این مشکل را کاهش می‌دهد.

۲. درباره‌ی فیلترسازی (attention-based filtering):

(آ) مدل با چه معیارهایی تصمیم می‌گیرد کدام نواحی تصویر را در اولویت قرار دهد؟

(ب) این عمل (انتخاب اینکه به چه مکانی توجه شد) چه تأثیری بر کیفیت تحلیل دارد؟

الف) مرحله آموزش، student با روشی مبتنی بر Attention بر روی هر پیکسل اهمیت می‌دهد، اولویت‌بندی می‌کند. اهمیت هر پیکسل بر اساس مقدار Attention و همچنین مقدار Classification Loss تعیین می‌شود. طبقاً به اهمیت هر پیکسل، اولویت‌بندی می‌شود. مقدار مابقی از اهمیت بیشتر بر مواردی که به آن توجه شده است، اولویت‌بندی می‌شود.

ب) زمانیکه با استفاده از Attention می‌توانیم اولویت‌بندی کنیم، اهمیت هر پیکسل را می‌توانیم بر اساس مقدار Attention و همچنین مقدار Classification Loss تعیین کنیم. این روش به ما کمک می‌کند تا بتوانیم به راحتی اولویت‌بندی کنیم و به این ترتیب، می‌توانیم به راحتی اولویت‌بندی کنیم.

۳. در مورد فرایند بازسازی (reconstruction):

(آ) چرا توانایی افزایش وضوح ورودی‌های کم کیفیت در کاربردهای دنیای واقعی ارزشمند است؟

(ب) کدام انواع اشیاء یا صحنه‌ها بیشتر از این قابلیت بهبود بهره‌مند می‌شوند؟

الف) توی دنیای واقعی، برخلاف شرایط آزمایشگاهی و تئوری، داده‌ها اغلب کیفیت بالا و اون شرایط استاندارد رو ندارند، بنابراین اگر مدل بتواند با تکنیک‌های بازسازی نسبت به این موارد مقاوم شود، در واقع Representation اصلی تصویر را متوجه می‌شود، از لحاظ شهودی هم انسان تا حد زیادی از تصاویر کم کیفیت را می‌تواند به خوبی طبقه‌بندی کند، چرا که در واقع اون نمایش زیر لایه‌ای اشیاء رو متوجه شده است.

ب) اشیاء و صحنه‌هایی که بیشترین سود را می‌برند شامل موارد زیر هستند:

اشیای کوچک مثل سوزن

اشیای دارای اجزای باریک مثل مو

اشیای دارای مرز پیچیده مثل سیم

صحنه‌های شلوغ مثل شهر

تصاویر دوربین مداربسته یا کم‌وضوح

چون در همه این موارد، از دست رفتن چند جزئیات کوچک می‌تواند نتیجه نهایی را به شدت خراب کند.

۴.

(آ) این سه مؤلفه چگونه یکدیگر را تکمیل کرده و در مجموع یک مدل قدرتمند می‌سازند؟

(ب) در صورت حذف یکی از این تکنیک‌ها، چه ضعف‌هایی ممکن است در عملکرد مدل ایجاد شود؟

الف) این سه مؤلفه مکمل یکدیگرند، زیرا Attention-Based Token Removal هزینه محاسباتی را کاهش می‌دهد، ولی ممکن است مقداری اطلاعات را حذف کند. Patch-Level Self-Distillation کمک می‌کند Student با وجود این حذف‌ها، Representation‌های محلی و معنایی مشابه Teacher را حفظ کند. در نهایت Pixel-Level Reconstruction مدل را مجبور می‌کند جزئیات بسیار دقیق تصویری و مرزها را نیز در Feature‌های خود نگه دارد.

ب) گر Self-Distillation حذف شود، Representation‌های Patch ضعیف‌تر شده و اطلاعات Local Semantic کمتر حفظ می‌شوند.

اگر Attention-Based Token Removal حذف شود، هزینه محاسباتی و مصرف حافظه افزایش می‌یابد.

اگر Pixel-Level Reconstruction حذف شود، جزئیات ریز، مرزها و ساختارهای باریک ضعیف‌تر حفظ می‌شوند و کیفیت Dense Prediction کاهش پیدا می‌کند.

پرسش ۲. یادگیری خودنظارتی (۵۰ نمره)

الف) به طور کلی در روش‌های Self Supervised Learning تلاش بر این است که شبکه برای هر تصویر یک representation خروجی بدهد، به گونه‌ای که مفاهیم آن تصویر را در خود در بر داشته باشد. بسیاری از روش‌ها همچون روش‌هایی که در شکل می‌بینیم، این کار را با تلاش برای نزدیک کردن representation دو تصویر مشابه (positive pairs) انجام می‌دهند. با این حال چرا چرا برخی روش‌ها مانند SimCLR به نمونه‌ها نامشابه (negative samples) نیاز دارند تا خروجی مطلوبی داشته باشند؟

روش‌هایی مثل SimCLR به Negative Samples نیاز دارند، چون فقط نزدیک کردن Representation‌های Positive Pair می‌تواند به یک راه‌حل بد منجر شود که در آن شبکه برای تمام تصاویر Representation یکسان تولید کند. این پدیده Representation Collapse نام دارد. Negative Samples مدل را مجبور می‌کنند علاوه بر اینکه برای تصاویر مربوط به هم شباهت ($\text{Sim}(x_i, x_j)$) بین آنها را بالا ببرد، باید بتواند میان تصاویر غیر مرتبط فاصله بیاندازد، بنابراین دچار Collapse نمیشود.


ب) تحقیق کنید و بگویید دلیل اینکه چنین مشکلی در روش‌هایی چون BYOL رخ نمی‌دهد چیست.

BYOL بدون Negative Samples هم دچار Representation Collapse نمی‌شود، چون معماری و نحوه آموزش آن نامتقارن است. سه مؤلفه اصلی این موضوع عبارتند از:

- Predictor in Online branch
- Stop-Gradient on Target Branch
- EMA / Momentum Update of Target Network

Target Network مستقیماً با Gradient به روزرسانی نمی شود و تنها به آرامی از Online Network پیروی می کند. بنابراین Online Network مجبور است Representation یک هدف نسبتاً پایدار را پیش بینی کند و این دینامیک آموزشی از رسیدن ساده سیستم به Representation ثابت و بی معنا جلوگیری می کند.

(ج) در مقایسه ی BYOL می بینیم که این روش در برابر انتخاب برخی هایپرپارامترها همچون batch size و یا انتخاب transformation هایی که روی تصاویر اعمال می شوند مقاوم تر است (شکل ۲).



شکل ۲: BYOL: Bootstrap Your Own Latent


به نظر شما دلیل این موضوع چیست؟

BYOL نسبت به Batch Size مقاوم تر از SimCLR است، زیرا SimCLR از نمونه های دیگر Batch به عنوان Negative Samples استفاده می کند؛ بنابراین با کاهش Batch Size تعداد Negative ها کاهش یافته و کیفیت Contrastive Learning افت می کند. BYOL Negative Sample ندارد و در نتیجه وابستگی بسیار کمتری به Batch Size دارد.

همچنین BYOL نسبت به حذف بعضی Transformation ها مقاوم تر است، زیرا یادگیری آن تنها بر Contrast بین نمونه ها متکی نیست و از ساختار Online-Target، Predictor، Stop-Gradient و EMA برای تولید یک Target پایدار استفاده می کند. بنابراین تغییر Augmentation ها کمتر از SimCLR به فرایند یادگیری آن آسیب می زند.

با این حال Augmentation همچنان برای BYOL مهم است؛ نمودار نشان می دهد حذف شدید آنها عملکرد BYOL را هم کاهش می دهد.

(د) در برخی روش ها سعی می شود بازنمایی برش های بزرگ یک تصویر (global crops) به یکدیگر نزدیک و برش های کوچک local crops در عین حال که به بازنمایی برش های بزرگ نزدیک باشند، از یکدیگر دور شوند (شکل ۳).



شکل ۳: Representations. Global and Local Your Leverage

Global Crop های یک تصویر باید Representation های نزدیک داشته باشند، چون هرکدام بخش بزرگی از همان صحنه را دیده‌اند و Semantic کلی مشابهی دارند. "باید Global Views نزدیک باشند به همدیگر".

اما Local Crop ها ممکن است مربوط به اجزای کاملاً متفاوت تصویر باشند. اگر همه Local Crop ها نیز مجبور شوند به یک Representation مشترک نزدیک شوند، اطلاعات Part-Level و Fine-Grained از بین می‌رود. از طرفی برای Local Views شرط اصلی این هستش که مفاهیم مشترک به همدیگر نزدیک شوند، این کار Representation هایی می‌سازد که هم مفهوم کلی تصویر را می‌فهمند و هم تفاوت بین اجزای مختلف آن را حفظ می‌کنند.